

Structured Prediction

מקרי אלן

מקרים מוצגים דרך labels-מקרי ים מקרי

מקרי-מקרי לא מקרי

מקרי-מקרי מקרי (מקרי-מקרי מקרי)

Supervised

Natural Language Parsing: מקרי

מקרי: מקרי

מקרי: מקרי מקרי, מקרי מקרי, מקרי מקרי

מקרי מקרי מקרי מקרי מקרי?

1. מקרי מקרי מקרי מקרי מקרי

2. מקרי מקרי מקרי מקרי מקרי

מקרי מקרי מקרי מקרי מקרי

מקרי מקרי מקרי מקרי מקרי

מקרי מקרי מקרי מקרי מקרי

מקרי מקרי מקרי מקרי מקרי

NER
POS
Sequence Prediction Problems

Named Entity Recognition I

מקרי מקרי מקרי מקרי מקרי

(Location, Company, ...)

מקרי מקרי מקרי מקרי מקרי

מקרי מקרי מקרי מקרי מקרי

מקרי מקרי מקרי מקרי מקרי

1. מקרי מקרי מקרי מקרי מקרי

מקרי מקרי מקרי מקרי מקרי

2. מקרי מקרי מקרי מקרי מקרי

Part of Speech Tagging II

אם הדבר הזה נמצא בחלקים (אחר) המילים למיננו (כיון).
אגב: נראה שהדבר הזה לא מילים שלם פה לא האינו.
← נראה שהמילה באינסופיותה של הדקלר.

אז מה מידע יש לנו?

1. הסמכות של מילים: באילו הסמכות המילה saw

מופיעה בפועל וקולנו הסמכות כללית.

2. מילים שכלול: יש רצפים של חלקי מילים שלם מאוד לא סבירים.

אם ניתן לשלול גיוגים את המילה על המוקד שלה

3. מאפיינים מורפולוגיים: $adv \rightarrow 'ly'$

אפשר למצוא משהו על המילה מהמילה שלה.

מה פה (אסוף)

הערה: אפשר להגיד למצוא סקור (גופה) אם מסתמים קצת

מילים בודדות. אלא אנחנו צולקים פה ב-1000 הקוראים ...

אנחנו נראה להגיד את המצב הסטטיסטי שלנו

הערה: סדרה (sequence) של מילים מקריים Y_1, \dots, Y_n

היא שרשרת מרקובית (Markov Chain, הומאני, מדרגה ראשונה)

$$\forall i \quad P(Y_i | Y_1, \dots, Y_{i-1}) = P(Y_i | Y_{i-1})$$

$$(\Leftrightarrow) Y_i \perp \{Y_1, \dots, Y_{i-2}\} | Y_{i-1}$$

הסמכות מילית Y_1, Y_2, \dots, Y_n

$$(\Leftrightarrow) P(Y_{1:n}) = \prod_{i=1}^n P(Y_i | Y_{i-1})$$

הקנה נוסף: נסמן אצלי הסמכות החלטה $Y_i = \text{start}$ ק

למשלמים בה צה כמו לא להענין בשום דבר - רק/נותה

הערה: 2 סדרה של מילים Y_1, \dots, Y_n , X_1, \dots, X_n הן HMM

(Hidden Markov Model) אם ההסמכות המילית שלהם מקריים:


$$P(Y_{1:n}, X_{1:n}) = \underbrace{\prod_{i=1}^n P(Y_i | Y_{i-1})}_{P(Y_{1:n})} \cdot \underbrace{\prod_{i=1}^n P(X_i | Y_i)}_{P(X_{1:n} | Y_{1:n})}$$

↑ באות מילים של- Y הם שרשרת מקריים

ולא סמכות ההסמכות השלם

$$P(Y_{1:n})$$

Sequence Prediction Problems



BRNN: הולך מלמטה למעלה

$$P(Y_0 = 0) = 1 \quad P(Y_i | Y_{i-1}) = \begin{cases} Y_{i-1} + 1 & \text{w.p. } \frac{1}{2} \\ Y_{i-1} - 1 & \text{w.p. } \frac{1}{2} \end{cases}$$

סומר $\{Y_i\}_{i=1}^n$ הוא שרשרת מרקובית.

ונניח שנתבשר על X_1, \dots, X_n שרשרתים סגול שמתאר את המיקום, עם רעש:

$$P(X_i | Y_i) = \begin{cases} Y_i & \text{w.p. } \frac{1}{2} \\ Y_i + 1 & \text{w.p. } \frac{1}{4} \\ Y_i - 1 & \text{w.p. } \frac{1}{4} \end{cases}$$

הקטנה: 1. $Y_{i:n}$ הם שרשרת מרקובית.

2. הנח"ה X_i בלתי תלויים בהם דבר אחר חוץ מ- Y_i .

סומר אם נדע את Y_i כל איך אינפורמציה נוספת
על X_i מתקום אחר.

אלו הנחות הן
HMM

הנחה זו הניווט את חוסר ביטחון של ההולך של X .

סומר אחר מקומות שלנו, הרעש נדגם בהם עם

מחזק את קשר האינפורמציה או אינפורמציה סגול היה קצת הקורב

סדרת המילים POS

$X_{1:n}$ = המילים במשפט

$Y_{1:n}$ = המילים POS של המילים במשפט \rightarrow אלו הם המילים

יוניו שלכן $X_{1:n}, Y_{1:n}$ הם HMM.

האם ההנחות מתקיימות פה?

1. $Y_{1:n}$ הם שרשרת מרקובית: משמעות ההנחה פה היא

שכל מילה "ציון" משמעות המילים, מספיק לה "ציון" לכל ציג המילים

אחרים עוקבים במשפט. זה דו הניווט כי המילים באות קצת מקומות

אבל זה לא אומר מספיק \Leftarrow אפשרות שרשרת מרקובית

מסדר של אף אחד יותר (מילים 2-מילים אחרות...) אבל כמובן

למסיונות אחר.

Q.10 : Sequence Prediction Problems

קרי: POS והתחנה: HMM

2. X_i כ/א גילוי קלטון דער חול' מ Y_i תורה זו קדירה

לד מחייב! כי אם אלהינו לא "וקעים" מה המילה, גם

לא נקט מזה היום POS שלי, נולד אמוץ עליה חתמה משלנו חתימה.

: HMM לר פתור

(y, y') for transition probabilities, M the transition matrix

$t(y, y') = P(Y_i = y \mid Y_{i-1} = y')$ ככה? כלומר:

$$\forall y' \sum_y t(y, y') = 1$$

x_i - f w y_i - f w y or: emission probabilities. 2

$$e(w, y) = P(X_i = w | Y_i = y)$$

$$\sum_w e(w, y) = 1$$

Bill saw that man yesterday : 10/1/13

"	"	"	"	"
X ₁	X ₂	X ₃	X ₄	X ₅

Name Verb Conj Noun Adverb

"	"	"	"	"
Y ₁	Y ₂	Y ₃	Y ₄	Y ₅

$$P(X_{1:n}, Y_{1:n}) = t(\text{Name}, \text{start}) \cdot t(\text{verb}, \text{Name}) \cdot \dots$$

• e(Bill, Name) • e(Saw, Verb) • ... •

כל מה שיש לי - זה אצא לך e זה אצא לך

פחיתותה סמך המרחק שלה.

דוגמה: Sequence Prediction Problems

pos tags


vocabulary : Inference: HMM → POS

$\{t(i,j)\}_{i,j \in L}$, $\{e(w,i)\}_{w \in V, i \in L}$: HMM נתון על פניו של סדרת תווים
: word , (word) $X_{1:n}$: סדרת תווים

$$y^* = \underset{y_{1:n}}{\operatorname{argmax}} P(y_{1:n} | X_{1:n})$$

$$= \underset{y_{1:n}}{\operatorname{argmax}} P(y_{1:n} | X_{1:n}) \cdot P(X_{1:n})$$

$L = \{l_1, l_2, \dots, l_k\}$: סדרת תווים



$w_{y_{i-1} \rightarrow y_i} = t(y_i, y_{i-1}) \cdot e(x_i, y_i)$: סדרת תווים

וסימטריה : Viterbi Algorithm ? פתרון

$$\pi(t, j) = \max_{\substack{y_1, \dots, y_t \\ y_t = j}} P(y_{1:t}, X_{1:t})$$

$$\pi(t, j) = \max_{j'} \{ \pi(t-1, j') \cdot t(j, j') \cdot e(x_t, j) \}$$

↑

כאשר t הוא מספר התווים
הנבחרים עד ל- $t-1$ ו- j' הוא
התווים הנבחרים עד ל- $t-1$

$$\pi(1, j) = t(j, \text{START}) \cdot e(x_1, j)$$

↑

כאשר j הוא התווים
הנבחרים עד ל- 1

כאשר j הוא התווים הנבחרים עד ל- 1

Learning: HMM → POS : MLE

$$\ell(\{t(i,j)\}, \{e(w,i)\}) = \sum_{r=1}^M \sum_{k=1}^n [\log t(y_{i_k}^{(r)}, y_{k-1}^{(r)}) + \log e(x_k^{(r)}, y_k^{(r)})]$$

כאשר $\{x_{1:n}^{(r)}, y_{1:n}^{(r)}\}_{r=1}^M$: סדרת תווים

$t(i,j) = n_{ij} / \sum_k n_{ki}$, $e(w,i) = n_{wi} / \sum_k n_{wi}$: סדרת תווים

Maximum Entropy Markov Model : MEMM → POS

הם מודלים מסדר גבוהים של HMM

חסרון 1: ב-HMM לא ניתן להשתמש בכל features, כמו:
 - מודעות למיקום של תווים. כל עוד תווים שלא חוסמו או
 חוסמו נמצאים מאחורי - יש להם משקל שווה.
 - כל תווים נקראים במסלול היחיד (אם כי ישנם מודלים אחרים).

יש מודל discriminative. כלומר - אין אפשרות לפרק את ה- x ו- y אלא
 רק כקבוצה אחת. נחשב את ה- y .
 \Rightarrow לא ניתן לנתח את x .

$$P(y_{1:n} | x_{1:n}) = \prod_{i=1}^n P(y_i | y_{i-1}, x_{1:n}) = \quad (1)$$

conditional independence
פרמטר
 \downarrow

$$= \prod_{i=1}^n \frac{e^{\langle \Phi(y_i, y_{i-1}, x_{1:n}, i), w \rangle}}{Z(x_{1:n}, y_{i-1})}$$

כאשר Φ היא פונקציה ה-features של w ו- w יהיו הפרמטרים של המודל

APML 4-18-08
 המכונה הסכימית היא $\langle \Phi(y_i, y_{i-1}, x_{1:n}, i), w \rangle$ הכולל את כל ה-features.

אם w היא Φ ? כלומר, איך נבנה את ה-features?

Φ היא וקטור אורך R^d

$$\Phi(y_i, y_{i-1}, x_{1:n}, i) = \begin{pmatrix} 1 \\ \{y_i, y_{i-1}\} \\ 1 \\ \{x_i, y_i\} \\ 1 \\ \{pref_i, y_i\} \end{pmatrix} \begin{cases} \text{transition features} \\ \text{כלומר אינטראקציות בין } y_i, y_{i-1} \end{cases} \left. \begin{matrix} \\ \\ \end{matrix} \right\} (\text{מספר POS})^2$$

$$\begin{cases} \text{emission features} \\ \text{כלומר אינטראקציות בין } x_i, y_i \end{cases} \left. \begin{matrix} \\ \end{matrix} \right\} \begin{matrix} \text{מספר תווים} \\ \times \\ \text{מספר POS} \end{matrix}$$

$$\begin{cases} \text{prefixes } p_1, \dots, p_m \\ \{pref(x_i) = p_j, y_i = y\} \end{cases} \left. \begin{matrix} \\ \end{matrix} \right\} \text{מספר POS} \times m$$

כלומר, אנו מחפשים למעשה transition features ו- w כקבוצה אחת.
 עבור קבוצה אחת של y_i, y_{i-1} מופיעים במספרות קבועות.
 ואם לא, אזי (אולי אפילו לא) אנו הרבה במספרות (מחנה).
 מחלק למעשה - emission, כלומר קבוצה אחת של $(man, verb)$
 קבוצה אחת של x ו- y ו- w ו- m (מחנה)...

MEMM: Sequence Prediction Problem

Gradient Ascent: מציאת המקסימום

$$\nabla L = \sum_{r=1}^N \sum_{i=1}^n \left[\Phi(y_i^{(r)}, y_{i-1}^{(r)}, x_{1:n}^{(r)}, i) - \sum_{y'} P(y|y_{i-1}, x_{1:n}) \Phi(y', y_{i-1}, x_{1:n}, i) \right]$$

instances
transmissions
Expected value

Structured Perceptron

מקום חלקי לא הוחלט על פני ה-labels האפשריים, אולי יש חלק כאלה ואולי נרצה חלקי לא הסכם (אזכור POS-ים אפשרי אבל לא חיוני) מה ההסכם?

מקום חלקי לא צעד בעולם, נקראת לא השוואה כולה כאלה לא השוואה האפשרית.

ואם במקום חלקי משהו מקומי זה יאמר שווה קשה חלקי, למשל פרספטון.

נניח שיש לנו פרקטיקל score: כפי חלקי נקודת על סדרה, פשוט נסכים נקודת על ה-features היחידים.

$$\text{score}(y_{1:n}, x_{1:n}) = \sum_{i=1}^n \text{score}(y_i, y_{i-1}, x_{1:n}, i) = \sum_{i=1}^n \Phi(y_i, y_{i-1}, x_{1:n}, i) \cdot w$$

שים לב שיש מאגר דומה לזה שיש לנו ב-MEMM...

הרבה אנחנו לא w האלמנטים: פרספטון יצור לנו לעולם לא זה בעצרת inference קשה.

Perceptron for Sequence Labeling

Input: $\{(x_{1:n}^{(r)}, y_{1:n}^{(r)})\}_{r=1}^N$

1. $w \leftarrow \vec{0}$ / random

2. for $r = 1 \dots N$:

2.1

2.2

$\hat{y}_{1:n} \leftarrow$ find the seq of y s that maximizes the score = do inference

$w \leftarrow w + \eta \left(\sum_{i=1}^n \Phi(y_i^{(r)}, y_{i-1}^{(r)}, x_{1:n}^{(r)}, i) - \sum_{i=1}^n \Phi(\hat{y}_i^{(r)}, \hat{y}_{i-1}^{(r)}, x_{1:n}^{(r)}, i) \right)$

the correct answer
MEMM output

3. return w

↑
 פרספטון נרצה להעביר את הממוצע על פני w-ים שגורמים למקום האחרון
 MEMM output
 הסכם הנניח
 $P(y_{1:n}, x_{1:n})$

המשק: Sequence Prediction Problem

המשק: Structured Perceptron

איקטליזציה א מה פרסמטרן עולה:

מחיל מניחול כלולו של w , וכל סכום \sum (עלה inference

ונוטה בין האלה לבין מה שצו און מחמול:

אם זה אלה דבר, אין עצמון

אם יש הפסל בין החול לבין האלה, (עצמן אלה w).

זה דומה למה שצושים P-GD , אבל מחקום לקחה א הגוחל עצמון,

אוקחים א המקסימום מחין מסוים.