

ClusteringI מבוא ואלגוריתמים סטטיים

מוסיפים: המאטא פולס המציג הוא המה שמצא מובן וזה מובן

Unsupervised <=>

נרצה לחקור את המאטא שלנו ולמצוא את משהו - נרצה מובן  
שנסתיר את המאטא אבל לא תמיד אפשר להסתיר את כל המאטא.  
שאלה שנרצה לענות: כמה "סוגים" של שאלות יש לנו?  
מה הצירים והמרחב המאטא?

נפרט את המצייה:

יהי  $X = \text{אוסף נקודות}$

$d = \text{פונקציה מרחק } d: X \times X \rightarrow \mathbb{R}$  ונניח שהיא גמלה מטריקה.

$C = \text{קלאסטרים } K\text{-קטגוריה } K \text{ שמתקיים:}$

החיתוך ריק  $\forall i, j \quad C_i \cap C_j = \emptyset$

א הנוקודים נמצאים  $\bigcup_{i=1}^K C_i = X$

פונקציה מרחק אפשרית:

אנחנו מניחים את המרחקים בין הנוקודים מתוך הקלאסטרים

$$\arg \min_C \sum_{k=1}^K \sum_{x_i, x_j \in C_k} d(x_i, x_j)$$

הנחה: אנחנו יוצרים את  $K$  מראש.

אבל זו לא פונקציה איזומורפית, סתם נלכד את המרחק...

מאתר של John Kleinberg מ-NIPS 2002 עוסק במבנה

של קלאסטרים ומראה ש-3 המבנים הראשונים לא תמיד מתקיימים:

Scale Invariance → אפשר לפרש את המרחק של המרחק ולשנות את המרחק

Richness → אפשר לסדר את הנוקודים במרחק של קלאסטרים המרחק

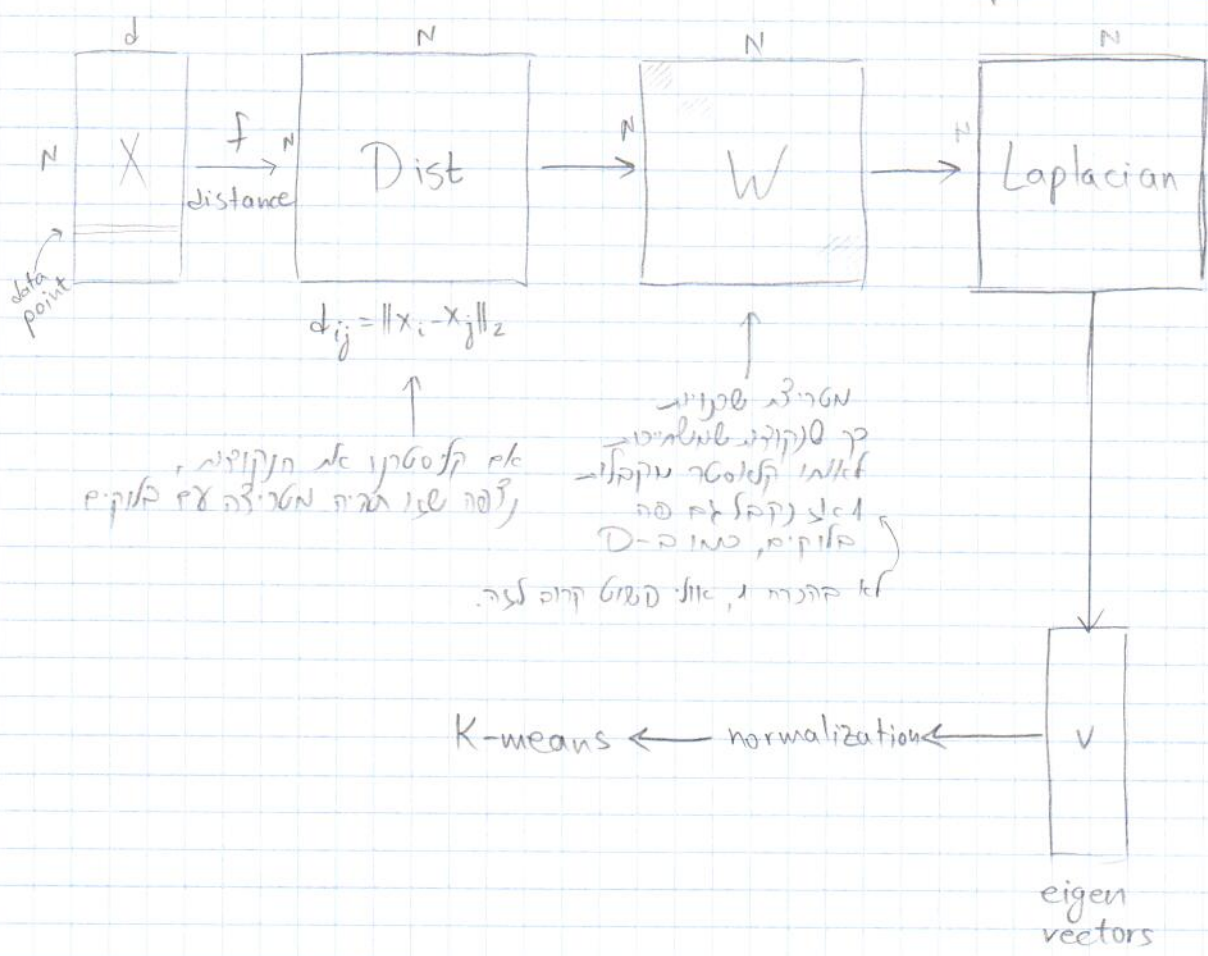
Consistency → אם נקדם את הנוקודים במרחק של קלאסטרים לא ישתנה

המרחק היחסי בין קלאסטרים, הקליסטור לא ישתנה.





# תרגון . Clustering Spectral Clustering II




מטריצה של קוורטות  
כך שנקודות שמשתייכות  
לזאת קלאסטר מקבלות  
1 כל נקודה לא 0  
באזורים, כמו D-  
לא קוורטות, אז כל נקודה מקבלת 0.


אם קוורטות לא חתוכות,  
נראה שיש גבול משתייכות  
באזורים

# איך אזורים בין Dist לבין W מטריצה השלמה?

הצעה 1: נעשה thresholding & Dist: הנקודות שצריך קטן מ- $\sigma$  יקבלו 1




איך נקבע את  $\sigma$ ?



נסתכל על ההיבט של המרחקים בין נקודות:  
נקבע  $\sigma$  כך שיהיה  $\sigma$  ממוצע המרחק בין הנקודות.

הצעה 2: נשתמש בקרנל גאוסית  $\sigma$  ל-

$$w_{ij} = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right)$$



ואם  $\sigma$  נקבע באופן דומה אולי למרחק קוורטות  
(נקודות לא  $\sigma \leq$  יהיו אלו יותר שלמים)

אם אנחנו רוצים קלאסטר הקלאסטר מיוצג ע"י וקטור קטן בעל המידע ע"י W.


# אן נמצא רבים קטור סגור?

נצטר מטריצה נוספת:



$$d_{ii} = \sum_j w_{ij} = \text{סכום השורה } i \text{ ב- } W$$

# אפשר להסתכל על שורש הקואסטרין כמכילת חץ מנותי סגור (אולי כמעט)



צבור של קטורים

קואסטרין:

נצטר:

$$|A| = \sum_{i \in A} 1$$

$$\text{vol}(A) = \sum_{i \in A} d_{ii} = \sum_{i \in A} \sum_j w_{ij}$$

נחשבו את ה-clustering אשר יהפוך ק:

$$\argmin_{A, B} \text{CUT}(A, B) = \sum_{\substack{i \in A \\ j \in B}} w_{ij}$$

יש לנו אלגוריתם שפותר את זה: ← פורם-פלקסון  $O(V^2)$   
 ← סופ אלגוריתם...

מה נמצא? outliers!

אם יש נקודה סופית רחוקה ממשור, פעולת נקב אמת

קואסטר ואל השאר קואסטר...

אן נסתר את זה? נוסף רגולריזציה לשמור סגור הקואסטרין

$$\argmin_{A, B} \text{CUT}(A, B) \cdot \left[ \frac{1}{|A|} + \frac{1}{|B|} \right]$$

↑ קרוב ל-1 עבור חלקה ל-1 שוויון של הקטורים  
 וקרוב ל-0 עבור חלקה חז-חז בין הקואסטרין

נחשבו זה NP-קשה אפילו לקרוב (ה)



## חלק II: Spectral Clustering

אפשרות אחרת להגדרת  $\text{vol}$  -  $\text{vol}(A)$

$$\arg \min_{A, B} \text{CUT}(A, B) \cdot \left[ \frac{1}{\text{vol}(A)} + \frac{1}{\text{vol}(B)} \right]$$

והבעיה הזו היא NP-קשה לקריש.

## # Graph Laplacian

$$L = D - W$$

$\uparrow$  Laplacian     $\uparrow$  degree     $\uparrow$  adjacency

יש לנו שם שכיח של  $L$  הוא  $D - W$ .  $D$  הוא מרחב

$$\begin{bmatrix} L & \mathbf{1} \end{bmatrix} = \begin{bmatrix} 0 \\ \mathbf{1} \end{bmatrix}$$

הערה: ההיחסון המלא  $L$  הוא  $0$ .

האם  $L$  הוא PSD?

$\Leftrightarrow$  Positive Semi Definite = PSD

כל הערכים העצמיים של  $L$  הם לא שליליים

$$f^T L f \geq 0, \quad f \text{ וקטור}$$

זה אומר שהערכים העצמיים של  $L$  הם לא שליליים

משקל  $f$  הוא קטן מ- $90^\circ$ .

נניח ש  $L$  הוא PSD

$$f^T L f = f^T D f - f^T W f = \sum_i d_i f_i^2 - \sum_{i,j} f_i f_j w_{ij} =$$

$$= \sum_i \sum_j w_{ij} f_i^2 - \sum_{i,j} f_i f_j w_{ij} =$$

$$= \frac{1}{2} \left( \sum_i \sum_j w_{ij} f_i^2 - 2 \sum_i \sum_j f_i f_j w_{ij} + \sum_j \sum_i w_{ij} f_j^2 \right) =$$

$$= \frac{1}{2} \sum_{i,j} w_{ij} \cdot \underbrace{(f_i - f_j)^2}_{\geq 0} \geq 0$$

$$0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$$

$\uparrow$  Fiedler Vector

# Spectral Clustering II : המשך

# מה שאר העצים העצמים נחשבים אליהם?

אם הקף הוא אולי של רכיבי קטנים שלם מנוקדים אחד ממשך,

אם עבור הקטור המניין שלו אנחנו במקומה המעמיקים רכיבים קטנים

אחד ואפסים בלבד השאר, הוא גם יהיה עם הערך העצמי 0.

במילים אחרות, אם הקטור קיים וקטור שמלג'ן אע"פ 0

מספר הוקטורים העצמים המעמיקים אע"פ 0 הוא מספר הקטורים.

↑  
זה לא חייב להיות ממש 0  
אולי קרוב ל-0 אם הם קצת קטנים  
ולא מופיעים באופן מובהק.

# אולי מה עם הערכים אולי הקטורים? Normalized Laplacian

$$L_n = D^{-1} L \quad : 2000, Shi \& Malik$$

זה נראה של ב שום למסך את זה להסבריו.

(מקורו להיות מקרי = Random Walk)

2. Ng, Jordan & Weiss : 2002

$$L_{sym} = D^{-\frac{1}{2}} \cdot L \cdot D^{-\frac{1}{2}} = I - D^{-\frac{1}{2}} W D^{-\frac{1}{2}}$$

↑ מתקיים ב אמונה קטנים יותר מתקיים ב שום קטנים חזקה

המטריצה היא נראה סימטרית, וגם PSD

נקרא את ה-notes  
לה

# מילים, האלגוריתם להצגתו:

נקט:  $x_i \in \mathbb{R}^d$

1. חשב  $S_{ij} = \|x_i - x_j\|$  מתקיים  $S_{nn}$

2. חשב  $W_{nn}$  מתקיים שנייה  $W_{ij} = \exp\left(-\frac{S_{ij}^2}{2\sigma^2}\right)$

אם  $\sigma \triangleq$  ith percentile of S

3. חשב  $D_{ii} = \sum_j W_{ij}$  מתקיים  $D_{nn}$  חזקה זרקה:

$$D_{ij} = 0, i \neq j$$

4. חשב  $L_{sym} = I - D^{-\frac{1}{2}} W D^{-\frac{1}{2}}$  מתקיים

5. חשב את k הוקטורים העצמים הראשונים:  $U = \begin{bmatrix} | & | & & | \\ u_1 & u_2 & \dots & u_k \\ | & | & & | \end{bmatrix}$

ב- k נקרא את שטח ה-eigen-gap.

6. חשב T שהיא נראה של השורה של U:  $T_i = \frac{U_i}{\|U_i\|}$  מתקיים שנייה שנייה חזקה

7. חשב k-means אוליטור השורה של T. כיוון יהיו קטנים.



# t-distribution Stochastic Neighbour Embedding t-SNE III

# נניח שיש לנו אלוס וקודים  $X_i \in \mathbb{R}^d$

נקבעה זעשית embedding של  $X$  ב- $d$  :  $Y_i \in \mathbb{R}^d$   $d \ll p$

ק שמתרחקים לא ילגנו הרבה, כלומר  $d_{ij} \approx d'_{ij}$

$$d_{ij} = \|x_i - x_j\|$$

אלא לא קאמא אכנסה לנו אטמא אג ב המתרחקים אלא אג (הזמיון -

נקבעה שטחים יישורו שטחים אלא שחור אכנסה לנו מתקופות חזקות.

# נסגל אג זה כמו הלוך מתקד :

$$p_{j|i} = \frac{\exp(-d_{ij}^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-d_{ik}^2 / 2\sigma_i^2)}$$

המתרחקים אכנסה לנו  $j-i$

ושכשו נקבעה להתרחק סין ההתפלגות יהיה קטן, ונקודות אלא זה

קטנה מתרחק - KL

$$\argmin_Y C = \sum_i KL(P_i \| Q_i)$$

המתפלגות של מתרחק מ- $i$  ב- $X$

המתפלגות של מתרחק מ- $i$  ב- $Y$

$$q_{j|i} = \frac{\exp(-d'_{ij}{}^2 / 2\sigma'_i{}^2)}{\sum_{k \neq i} \exp(-d'_{ik}{}^2 / 2\sigma'_i{}^2)}$$

$$H(P_i) = -\sum_j P_{ij} \log_2(P_{ij})$$

perplexity :  $2^{H(P_i)}$  → זה קצת מייצג אג כמה השכנים

$$KL(P_i \| Q_i) = \sum_j P_{ji} \log \frac{P_{ji}}{Q_{ji}} \quad : \underline{KL}$$

$$\Rightarrow \argmin_Y \sum_i KL(P_i \| Q_i) = \sum_i \sum_j P_{ji} \log \frac{P_{ji}}{Q_{ji}}$$

נשים אג שזה לא סימטרי : אפילו אג נשנה מאדף אלא זנף

אלא זנף מאדף מאדף קטן (כלומר נקודות רחוקות), זה יהיה

חסר קטן מסכימה ≤ שחור אכנסה לנו. ≤ זה לא סימטרי.

# נילחם  $Y$  סולסן אקרא ואל נחשב אג המתרחקים ונסגל אג החדות :

$$\frac{\partial C}{\partial y_i} = 2 \cdot \sum_j (P_{ji} - Q_{ji} + P_{ij} - Q_{ij})(y_i - y_j)$$

$$y^{(t)} = y^{(t-1)} + \eta \frac{\partial C}{\partial y} + \alpha(t) [y^{(t-1)} - y^{(t-2)}] \quad : \text{momentum}$$

t-SNE

## t-SNE : המטרה

מה הקצויות ב-SNE שהלגנו קצויות הקודם?

1. מנגיש - outliers

2. קומידה של המימד קו מקודים את המימד, לא נוב למימד

את  $\hat{\mu}$  הממוקם את א שיהיה אנו underestimation של נקודות

קודים, א שיהיה over-estimation של נקודות מוקד.

א הנקודה השנייה סימרי - t-SNE - קצויות t-distribution (המפלגה t)

המפלגה t היא כמו המפלגה נורמלית אבל פז נקודות.

א נלמדה קודם של המפלגה t:

$$q_{ji} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_k (1 + \|y_i - y_k\|^2)^{-1}}$$

קודם, מקום המימד א המימד נורמלי של  $j$  סימני  $i$ , המ

המפלגה של המפלגה של  $i$  ו- $j$ :

$$c = \arg\min_y KL(P \| Q)$$

↑ המפלגה מוקדית - המפלגה של  $i$  ו- $j$

$$\frac{\partial c}{\partial y_i} = 2 \sum_j (p_{ji} - q_{ji}) \cdot (y_i - y_j) \cdot [\text{term}]$$

וכך קו נוקים סתם נקודות - outliers.